2026

Voz del paciente

ANÁLISIS DE REVIEWS: SENTIMIENTOS Y TEMAS

KARINA MIRANDA RUÍZ

RESUMEN

El presente proyecto tiene como objetivo analizar la ***voz del paciente*** a partir de reseñas publicadas en Google Maps para distintas sucursales de una institución de servicios de salud. A partir de un proceso de web scraping se recopilaron más de 33 mil reseñas, de las cuales 24,613 contenían comentarios en texto y fueron utilizadas para el análisis.

Los comentarios fueron sometidos a un proceso de limpieza y preprocesamiento, incluyendo normalización y lematización del texto. Posteriormente se aplicó un modelo de análisis de sentimientos utilizando la librería *pysentimiento*, el cual permitió clasificar cada comentario en categorías (positivo, negativo o neutral) y detectar emociones específicas. A partir de las palabras más frecuentes se identificaron temas importantes y recurrentes relacionados con distintos aspectos de la experiencia del usuario, tales como tiempo de atención, servicio del personal, estudios realizados, citas, costos, instalaciones y óptica.

Los resultados muestran una distribución equilibrada entre comentarios positivos y negativos. Asimismo, algunos temas, particularmente el servicio, aparecen de manera recurrente tanto en los comentarios positivos como negativos, lo que sugiere que constituyen un elemento central en la experiencia reportada por los usuarios. Este tipo de análisis permite aprovechar grandes volúmenes de comentarios abiertos para comprender mejor las percepciones de los pacientes y apoyar la identificación de áreas de oportunidad, así como buenas prácticas que se puedan extrapolar al resto de las sucursales.

INTRODUCCIÓN

Analizar los comentarios que los usuarios dejan en plataformas digitales puede ayudar a entender cómo se percibe la calidad del servicio desde la misma voz del paciente. Este tipo de información se genera constantemente y puede ofrecer pistas sobre la experiencia en diferentes etapas del servicio. En estos espacios es común encontrar referencias a aspectos como la facilidad para agendar citas, los tiempos de espera, la atención durante la toma de muestras, el trato recibido en la sucursal, entre otros.

Hoy en día muchas plataformas generan constantemente grandes cantidades de información en forma de texto libre. Revisar todos esos comentarios manualmente no solo es tardado, sino también poco práctico cuando el volumen crece. Por esta razón, las técnicas de procesamiento de lenguaje natural (Natural Language Processing, NLP) se han convertido en una herramienta útil para analizar este tipo de datos y encontrar patrones o tendencias dentro de los comentarios de los pacientes.

En este proyecto se analizaron comentarios publicados en Google Maps por pacientes que acudieron a una institución que ofrece servicios de laboratorio clínico, además de servicios de óptica y taller de lentes. A partir de esta información se desarrolló una solución basada en técnicas de procesamiento de lenguaje natural enfocada principalmente en el análisis de sentimientos y en la identificación de temas relacionados con la experiencia de servicio. Como resultado del análisis fue posible identificar siete temas principales que aparecen con frecuencia en los comentarios, lo que permitió explorar qué aspectos del servicio suelen mencionarse con mayor frecuencia por parte de los pacientes.

Este tipo de análisis también puede ser útil desde una perspectiva administrativa. Por ejemplo, permite observar qué sucursales concentran una mayor proporción de comentarios positivos o identificar temas que aparecen con mayor frecuencia en comentarios negativos. Esta información puede ayudar a reconocer prácticas que funcionan bien o a detectar áreas donde podrían realizarse mejoras.

Durante el desarrollo del proyecto también se identificaron algunos retos. Uno de ellos fue la obtención de los datos mediante web scraping en Google Maps, ya que la plataforma tiene ciertas limitaciones para la extracción de información. Para realizar el proceso se utilizó un repositorio disponible en GitHub, aunque fue necesario recopilar manualmente la URL de cada sucursal. Considerando que la institución cuenta con más de 300 sucursales, este proceso tomó tiempo y además no todas las ubicaciones tenían comentarios disponibles.

Otro desafío importante fue la limpieza y preparación del texto antes de realizar el análisis. Al trabajar con comentarios en español, muchas palabras aparecen con distintas variaciones. Para reducir este problema se utilizó lematización, que permite agrupar palabras con la misma raíz (por ejemplo: lento, lenta, lentos o lentas). Sin embargo, en algunos casos esto generó pequeñas confusiones, como cuando palabras con formas similares pertenecían a contextos diferentes, por ejemplo “lento” y “lentes”. Finalmente, se generaron visualizaciones sencillas con el objetivo de presentar los resultados de forma clara y facilitar su interpretación.

OBJETIVO

OBJETIVO GENERAL

Analizar los comentarios publicados en Google Maps por pacientes que han acudido a una institución que ofrece servicios de laboratorio clínico, servicios de óptica y taller de lentes. Para ello se utilizan técnicas de procesamiento de lenguaje natural que permiten identificar sentimientos en los textos, así como la detección de algunos temas recurrentes reflejados en los comentarios de distintas sucursales.

OBJETIVOS ESPECÍFICOS

- Consolidar información (texto) obtenida a través de web scraping, en un formato que permita su explotación.
- Realizar un análisis de sentimientos para identificar el mensaje principal de los comentarios y así encontrar áreas de mejora en el servicio.
- Entender los tópicos principales y su connotación positiva o negativa de los comentarios.
- Ubicar la existencia de patrones y su posible influencia.
- Analizar los comportamientos por sucursal.

ALCANCE DEL PROYECTO

Este proyecto consiste en un análisis orientado a comprender algunos de los patrones recurrentes que aparecen en los comentarios publicados por los pacientes sobre el servicio recibido en distintas sucursales. A partir de este análisis se busca identificar de manera general cómo el paciente percibe diferentes aspectos de la experiencia de servicio.

Para ello se utilizaron herramientas de procesamiento de lenguaje natural (NLP), particularmente técnicas de análisis de sentimientos mediante la librería *pysentimiento* (modelos preentrenados), que permiten clasificar cada comentario de acuerdo con su intención general (positiva, negativa o neutral). Además, se identificaron algunos de los temas que aparecen con mayor frecuencia en los comentarios, lo que permite tener una idea de qué aspectos suelen mencionarse más en las opiniones de los pacientes; este tipo de información también puede ayudar a reconocer buenas prácticas y transferirlas a otras sucursales con posibles áreas de mejora.

Como parte del alcance del proyecto también es importante considerar algunas limitaciones. Aunque se trata de una institución con un número considerable de sucursales, varias de ellas son más nuevas que otras, por lo que la cantidad de comentarios disponibles no es la misma; esto puede hacer que en algunas sucursales la información sea más limitada y no necesariamente representativa, mientras que en otras esté más consolidada. Otra limitación es que, dentro del análisis realizado, no fue posible identificar de manera automática la posible presencia de cuentas automatizadas o bots dentro de los comentarios.

Finalmente, para mantener el enfoque del análisis en el contenido textual de las opiniones, no se incluyeron otros elementos disponibles en la plataforma, como las respuestas del propietario del establecimiento, la fecha de dichas respuestas o el rating proporcionada por los pacientes.

MARCO TEÓRICO

El procesamiento de lenguaje natural (NLP) es un subcampo de la inteligencia artificial que mezcla la lingüística y las ciencias de la computación, enfocado en la interacción entre computadoras y humanos mediante el lenguaje natural. El objetivo final del NLP es entender, interpretar y generar lenguaje humano de tal forma que tenga significado y sea útil. De acuerdo con Cuantum Technologies (2024), NLP incluye un amplio rango de técnicas y metodologías que generalmente pueden clasificarse en algunas categorías, como son procesamiento de texto, análisis de sintaxis, análisis de semántica y análisis pragmático, siendo este último el nivel final de análisis que considera el contexto y la intención prevista detrás de las palabras. Esto va más allá del significado literal de las palabras o las oraciones hasta intentar entender la intención del hablante.

Una de las muchas aplicaciones del NLP es el análisis de sentimientos. El análisis de sentimientos abarca un conjunto de técnicas que muchos negocios utilizan para analizar los comentarios de los clientes y medir la opinión pública y los sentimientos sobre sus productos o servicios.

Para lograr esto, un modelo de NLP procesa el texto en tokens (Cuantum Technologies, 2024, p. 31), unidades pequeñas de texto que pueden ser palabras, frases o incluso caracteres. Es importante

notar la existencia de las stopwords, que son palabras vacías que no nos proporcionan información relevante, como artículos, preposiciones, conjunciones, etc.

Algunos de los retos que presentan estos modelos son la ambigüedad que pueden tener múltiples palabras dependiendo del contexto, la diversidad de idiomas, expresiones locales, sarcasmo e ironía. También pueden presentarse dificultades al identificar entidades dentro del texto (NER, Named Entity Recognition), la función gramatical de cada palabra (POS, Part-of-Speech) o al medir exactamente el sentimiento detrás de un texto (positivo, negativo o neutral), ya que una misma oración puede expresar diferentes emociones, lo que puede dificultar su clasificación.

Con la intención de solucionar algunos de estos retos mencionados, se creó la librería *pysentimiento* (Pérez et al., 2023), una biblioteca de código abierto en Python diseñada para facilitar tareas de procesamiento de lenguaje natural (NLP) social y minería de opiniones, con soporte multilingüe para español, inglés, italiano y portugués.

Esta herramienta permite automatizar la extracción de sentimientos, emociones e incluso discurso de odio e ironía a partir de textos generados por usuarios, principalmente en redes sociales.

Para su desarrollo, los autores consideraron el uso de modelos preentrenados de última generación (basados en Transformers), tanto generales como especializados en el dominio de redes sociales, como BERTweet (inglés), RoBERTuito (español) y BERTweetBR/BERTabaporu (portugués), seleccionando los de mejor desempeño tras una evaluación exhaustiva con diversos datasets representativos.

Además, realizaron un análisis de equidad (fairness) para detectar posibles sesgos demográficos y compararon su eficacia frente a otras herramientas populares de la industria, demostrando un rendimiento superior en la mayoría de los casos analizados.

Así mismo, *pysentimiento* genera scores y clasificaciones.

Score en sentimientos: El análisis de sentimientos se define fundamentalmente como detección de polaridad, donde el objetivo es predecir si un texto tiene un sentimiento general positivo, negativo o neutral.

Score en emociones: La detección de emociones se presenta como un refinamiento de la polaridad. Los puntajes clasifican el texto en categorías específicas: ira, asco, miedo, alegría, tristeza y sorpresa.

Como se mencionó anteriormente, otra tarea del NLP se centra en analizar la semántica de las oraciones. Para este caso es necesario el preprocesamiento del texto, como la lematización, que se basa en definir una forma base o lema de las palabras (palabra raíz) y clasificar todas sus flexiones como una sola. Por ejemplo, lento, lenta, lentos, lentas pueden quedar unificadas al definir lento como lema.

En este caso, la librería *spaCy* (Honnibal et al., 2020), junto con el modelo lingüístico `es_core_news_lg` para texto en español (Explosion AI, 2024), facilita la normalización del texto antes de realizar el análisis de temas que agrupe distintas palabras bajo una misma raíz.

En el análisis de experiencia del usuario, la visualización geoespacial de métricas de sentimiento facilita la comparación entre distintas sucursales permite identificar patrones territoriales que no

siempre son evidentes en tablas o gráficos convencionales. Para ello se utilizó la librería *Folium* (Python Visualization Library, 2024), que permite generar mapas interactivos en formato HTML basados en *OpenStreetMap*.

El mapa integra en una sola visualización la ubicación geográfica de las sucursales, el volumen de reseñas y un índice agregado de sentimientos, lo que permite sintetizar los resultados sin perder claridad.

METODOLOGÍA

El presente trabajo se desarrolló utilizando una computadora con procesador 12th Gen Intel(R) Core(TM) i5-12500H (2.50 GHz), una GPU de 4 GB y 8 GB de memoria RAM (7.63 GB utilizables), dentro del IDE Visual Studio Code versión 1.110.1. Se utilizó Python 3.13.7 como lenguaje de programación.

Para iniciar y obtener los datos se realizó un web scraping de los comentarios disponibles en Google Maps de diferentes sucursales mediante la herramienta *google-reviews-scraper-pro* (Khananaev, s. f.). Este es un desarrollo disponible en GitHub que permite realizar scraping de reseñas públicas, para lo cual es necesario contar previamente con una lista de las URL de los lugares a analizar. Una vez realizada la extracción de comentarios, la aplicación genera una base de datos *SQLite*. Algunas de las tablas utilizadas se muestran a continuación (ilustración 1), así como su relación con el archivo de Excel que contiene el nombre de cada sucursal.

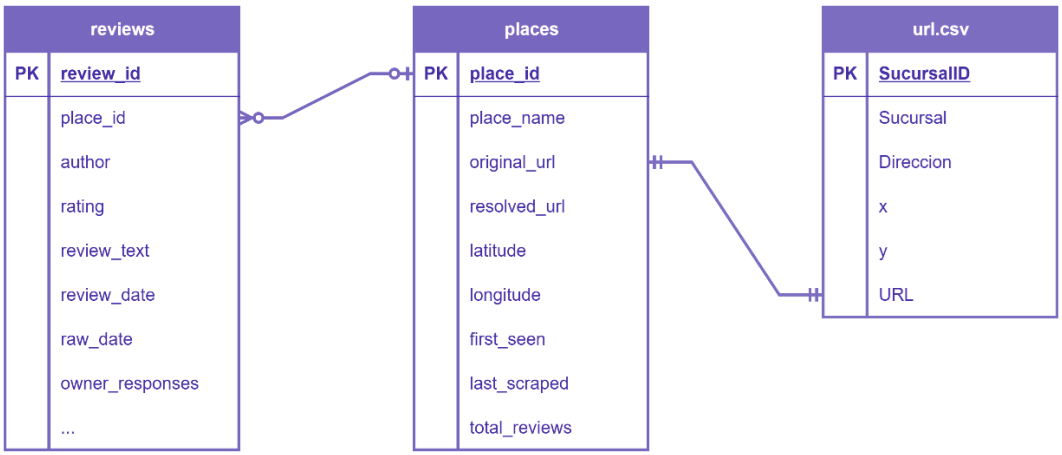

Ilustración 1 Diagrama entidad-relación que muestra tres tablas: reviews, places y url.csv, con sus campos y relaciones. Destacan claves primarias y foráneas que conectan reviews con places, y places con url.csv, indicando estructura de base de datos para gestión de reseñas y ubicaciones.

Para procesar los datos, y considerando que se trata de observaciones de tipo texto, se realizó una limpieza sencilla habitual en este tipo de análisis que consistió en extraer el texto de `review_text`, que guarda el comentario en un string con formato JSON, para posteriormente limpiar el contenido y conservar únicamente caracteres alfabéticos, así como signos de admiración y de interrogación. También se eliminaron emoticones presentes en `owner_responses`, ya que, aunque la librería *pysentimiento* puede gestionar este tipo de caracteres, en este trabajo no abarca el uso de la función `preprocess_tweet` que sirve para manipular hashtags, emojis, repetición de caracteres y demás.

Una vez obtenidos los comentarios limpios, y considerando que no se cuenta con una variable de respuesta (label) -es decir, las observaciones utilizadas no estaban previamente etiquetadas-, se utilizó un modelo predictivo de análisis de sentimientos implementado en el paquete *pysentimiento* versión 0.7.3. Este paquete se basa en modelos de deep learning preentrenados con arquitectura Transformer. Para su uso se configuró la función `create_analyzer` para generar análisis de sentimientos y emociones en español, lo que posteriormente permitió utilizar la función `predict`.

Este modelo asigna un score de probabilidad que indica qué tan probable es que un comentario tenga una intención positiva, negativa o neutral. Adicionalmente, el modelo permite clasificar el comentario en una de las seis emociones disponibles: ira, asco, miedo, alegría, tristeza y sorpresa. Para los análisis posteriores se imputaron las reseñas que no contienen comentarios.

Adicional a la información generada por *pysentimiento*, se realizó un análisis exploratorio para identificar las palabras que aparecen con mayor frecuencia en comentarios con sentimientos positivos y negativos. Para ello se descartaron las palabras conocidas como stopwords, predefinidas en la librería *nltk* para español, como son artículos, preposiciones y conjunciones. A esta lista se agregaron algunas palabras adicionales que aparecían en la gráfica de nube de palabras pero que no aportaban información relevante, por ejemplo, errores ortográficos como la letra “q”, utilizada habitualmente como abreviatura de “que”, o palabras muy recurrentes que no aportan información específica, como “sucursal”, que puede utilizarse en distintos contextos.

Una vez identificadas las 30 palabras más repetidas por tipo de sentimiento, estas se agruparon en siete temas principales: tiempo de atención, servicio del personal, estudios realizados, citas, costos, instalaciones y óptica.

Para analizar mejor estos temas fue necesario utilizar la librería *spaCy*, especializada en lematización. Para ello se definieron las palabras raíz a utilizar en el análisis para cada tema, y la librería se encarga de agrupar los distintos tokens considerando las flexiones propias del idioma español. Durante este proceso surgió una dificultad con la palabra “lento”, utilizada en el tema de tiempos de atención, ya que al ser muy frecuente la palabra “lentes”, el modelo tendía a clasificarla incorrectamente. Para solucionarlo se condicionó primero la identificación del lema “lente” cuando apareciera como sustantivo, y posteriormente el lema “lento” cuando se identificara como adjetivo.

Cabe mencionar que un comentario puede clasificarse en más de un tema. Por ejemplo, un comentario podría mencionar un trato amable durante la toma de sangre, lo cual podría relacionarse tanto con el servicio del personal como con el proceso de estudios realizados. Con esta información, para obtener una medida general de los temas abordados, se calculó el promedio de comentarios que mencionan cada tema, diferenciando entre comentarios positivos y negativos.

Posteriormente se realizó una agrupación por sucursal para analizar el comportamiento de cada una. En esta etapa se calcularon algunas medidas descriptivas, como el promedio del score positivo, el promedio del score negativo y el total de comentarios. Asimismo, se construyó un índice adicional, llamado Índice Sentimientos, que consiste en un promedio del score positivo y negativo, multiplicando el score negativo por -1, con el objetivo de obtener un rango entre -1 y 1 y así contar con una medida global que fue utilizada en algunas colorimetrías.

Una vez agrupada la información por sucursal, también fue posible identificar los temas más recurrentes en cada una y clasificar las sucursales según la proporción de comentarios positivos y negativos.

Finalmente, para facilitar la interpretación de los resultados se desarrollaron diferentes visualizaciones. Entre ellas se incluyeron nubes de palabras, gráficas de barras horizontales para representar los temas identificados y gráficas de dispersión para visualizar el comportamiento de las distintas sucursales. Adicionalmente, se desarrolló un mapa interactivo que permite visualizar de forma geográfica la información general sobre los comentarios recibidos en cada sucursal.

En el mapa, el tamaño del círculo corresponde a una normalización min-max del total de reseñas por sucursal, escalado en un rango de 8 a 35 píxeles, mientras que el color representa el índice Sentimientos previamente definido.

Al seleccionar cada sucursal, el mapa despliega un popup con información adicional, incluyendo el índice de sentimientos, el porcentaje de reseñas positivas - junto con un delta de score positivo promedio - y negativas, y los tres temas más recurrentes, junto con su sentimiento dominante y el porcentaje correspondiente.

Con el fin de resumir las etapas principales del proceso de análisis, en la ilustración 2 se muestra el flujo metodológico seguido en este proyecto.

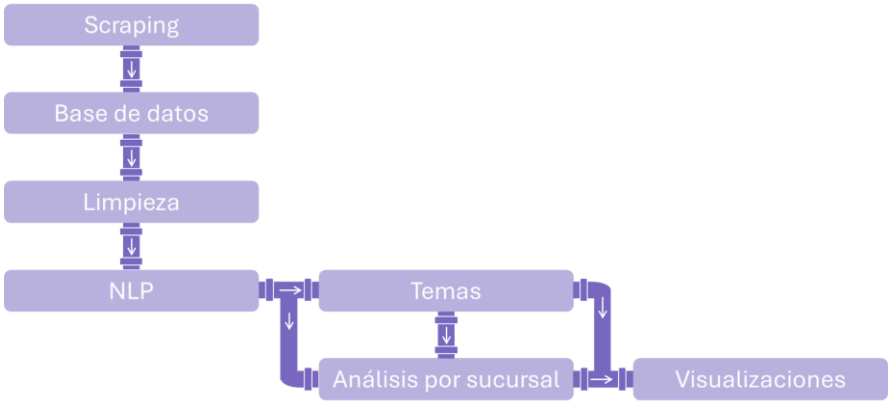

Ilustración 2 Diagrama de flujo que muestra proceso de análisis de datos desde scraping hasta visualizaciones. Incluye etapas: base de datos, limpieza, NLP, temas, análisis por sucursal, con flechas que indican secuencia y retroalimentación entre temas y análisis.

Cabe mencionar que los datos utilizados en este trabajo corresponden a reseñas públicas disponibles en Google Maps, por lo que no se recolectó ni utilizó información personal identificable de los usuarios. El análisis se realizó únicamente con fines académicos y de investigación, respetando el carácter público de la información.

RESULTADOS

A partir del proceso de web scraping se obtuvieron un total de 33,205 reseñas correspondientes a 124 sucursales, de las cuales sólo 24,613 contenían comentarios en texto (necesarios para técnicas de procesamiento de lenguaje natural), por lo que el análisis se realizó únicamente con estas observaciones. Después del proceso de limpieza y preprocesamiento del texto, los comentarios fueron analizados mediante el modelo de análisis de sentimientos implementado en la librería *pysentimiento*. Adicionalmente al análisis de sentimientos, el modelo permitió identificar emociones específicas presentes en los comentarios. En la ilustración 3 se muestra la distribución de emociones detectadas en las reseñas analizadas.

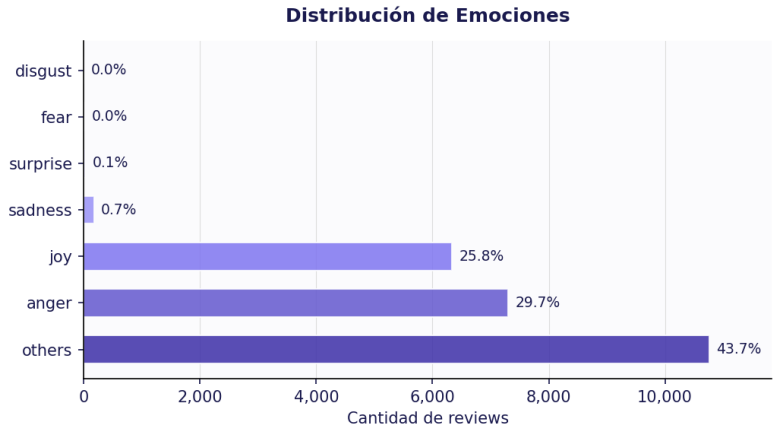

Ilustración 3 Distribución de comentarios en las diferentes emociones, proporcionada por pysentimiento.

Como se observa, la categoría más frecuente corresponde a others, utilizada por el modelo cuando el comentario no presenta una emoción predominante clara o cuando el contenido es principalmente descriptivo Le siguen las emociones de enojo y alegría, generalmente asociadas a experiencias negativas y positivas.

Con el fin de ilustrar el funcionamiento del modelo, en la tabla 1 se muestran algunos ejemplos de comentarios reales y su clasificación correspondiente.

Emoción	Comentario
others	ES UN LUGAR PARA HACER ESTUDIOS SENCILLOS
anger	ES INCREÍBLE EL TIEMPO DE ESPERA HORAS!!! DE NADA SIRVE SACAR CITA EN LÍNEA PÉSIMO SERVICIO !!!
joy	AGRADECIMIENTO TOTAL A QUIEN CREO SALUD DIGNA LA ATENCIÓN LOS PRECIOS Y TODO EN GENERAL ES REALMENTE DE PRIMER NIVEL!! SUPER AMPLIAMENTE RECOMENDABLE!!
sadness	LÁSTIMA QUE HAGAN FALTA VARIOS ESTUDIOS EN ESTA SUCURSAL
surprise	EQUIPO DE PRIMERA DE VERDAD ME SORPRENDIÓ EL PRECIO Y CALIDAD
fear	MUCHA GENTE DA MIEDO PASAR POR EL ÁREA DE LAS PRUEBAS COVID
disgust	JAMÁS VOLVERÍA ES EL PEOR LUGAR DEL TIPO EN EL QUE HE ESTADO!

Tabla 1 Ejemplos de comentarios clasificados en las diferentes emociones

Por otro lado, la distribución de comentarios en negativos, positivos y neutrales se muestra en la ilustración 4. Como se observa, la distribución de sentimientos es relativamente equilibrada, y la clasificación neutral no representa una gran proporción de los comentarios analizados.

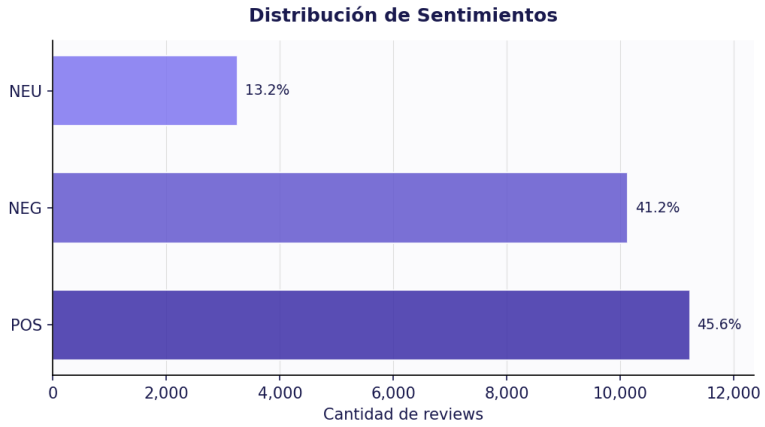

Ilustración 4 Distribución de comentarios en los diferentes sentimientos, proporcionada por *pysentimiento*. Negativos:10,133 reviews, Positivos: 11223 reviews

Ilustración 5. a Nube de palabras más frecuentes en reviews negativos

Ilustración 5.b Nube de palabras más frecuentes en reviews positivos

Como se puede ver en la ilustración 5.a, en los comentarios negativos destacan palabras como servicio, cita, estudio, atención, hora y pésimo, lo que sugiere que las experiencias negativas suelen estar relacionadas con tiempos de espera o problemas en la atención.

Por otro lado, en la ilustración 5.b, en los comentarios positivos aparecen con mayor frecuencia términos como excelente, servicio, atención, precios, buena y accesible, lo cual sugiere que los usuarios valoran principalmente la relación costo-beneficio y la calidad del servicio. (Ver anexo 1 para el top de 30 palabras por sentimiento positivo y negativo)

A partir de estas palabras frecuentes se identificaron siete temas principales (ilustración 6) presentes en las reseñas: tiempo de atención, servicio del personal, estudios realizados, citas, costos, instalaciones y óptica (ver Anexo 2 para la lista de palabras raíz usadas para clasificar los 7 temas).

En los comentarios negativos (Ilustración 6.a) aparecen con mayor frecuencia temas relacionados con los estudios y los tiempos de atención, mientras que en los comentarios positivos (Ilustración 6.b) destacan principalmente los costos y los estudios realizados.

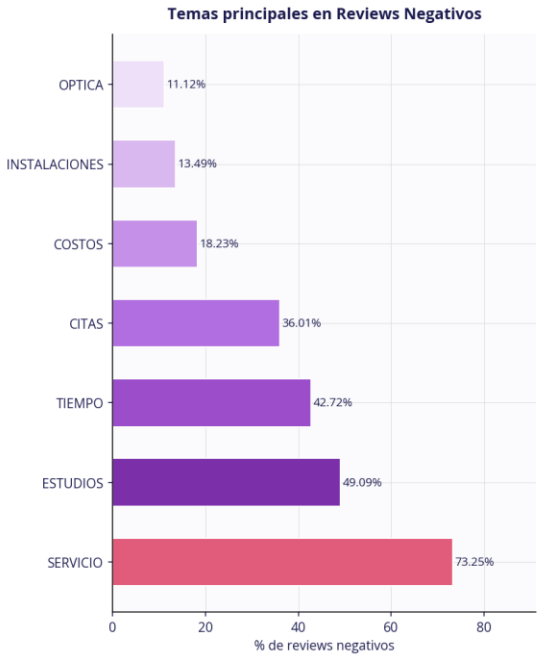

Ilustración 6. a Distribución de comentarios en los diferentes temas, en reviews negativos

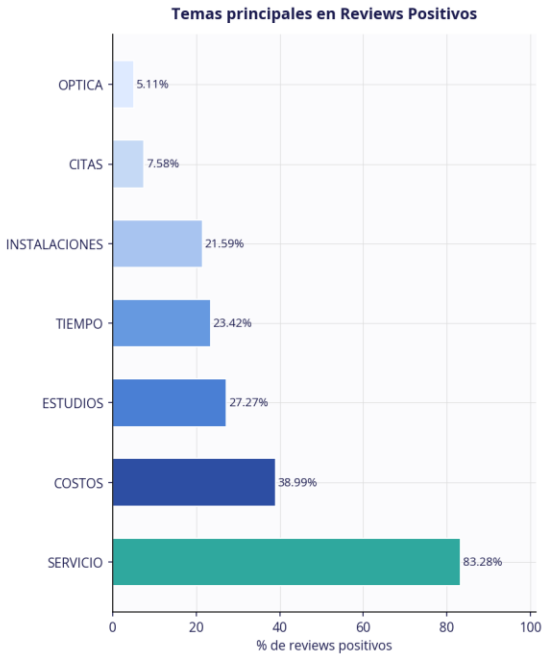

Ilustración 6.b Distribución de comentarios en los diferentes temas, en reviews positivos

Posteriormente se realizó un análisis agregado por sucursal, calculando el promedio del score positivo y negativo de los comentarios correspondientes a cada una. En la Ilustración 7 se muestra esta distribución: el tamaño de la burbuja es proporcional a la cantidad de comentarios disponibles por sucursal, mientras que el color corresponde a una escala global de sentimientos. Para visualizar la gráfica interactiva se puede consultar el enlace correspondiente de la gráfica de burbuja html (Ver Anexo 3).

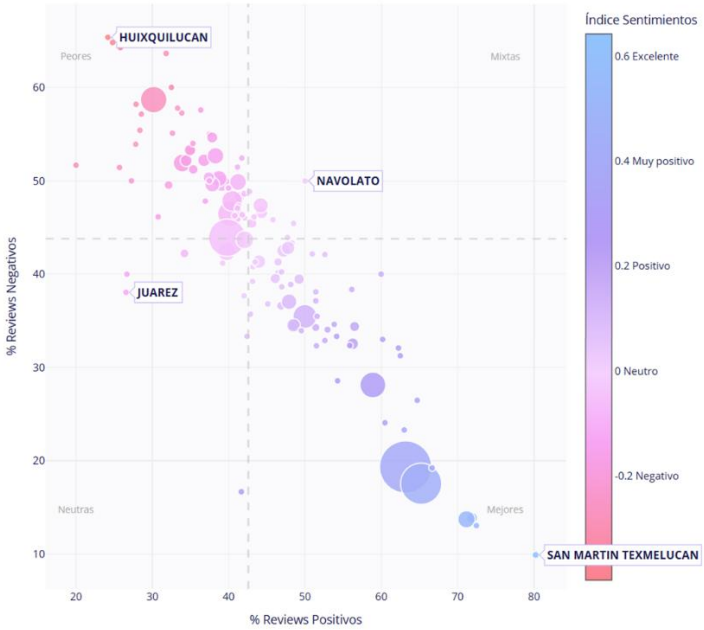

Ilustración 7 Mapa de posicionamiento de Sucursales.
% Reviews Positivos vs % Reviews Negativos | Tamaño = Total de comentarios | color = Índice global de sentimientos

En la gráfica se pueden observar distintos comportamientos entre sucursales. Por ejemplo, Huixquilucan presenta un alto porcentaje de comentarios negativos y una proporción menor de comentarios positivos. En contraste, San Martín Texmelucan muestra una tendencia opuesta, con una mayor proporción de comentarios positivos y pocos comentarios negativos.

También existen casos intermedios, como Juárez, donde los porcentajes de comentarios positivos y negativos se encuentran alrededor del 30 %, lo que podría interpretarse como una percepción relativamente neutra. Por otro lado, Navolato presenta aproximadamente un 50 % de comentarios positivos y un 50 % de comentarios negativos, lo cual sugiere una distribución mixta o polarizada de las opiniones de los usuarios.

Otro aspecto relevante es la relación entre los temas identificados en los comentarios y las distintas sucursales. Con este objetivo se analizó la proporción de comentarios asociados a cada uno de los temas definidos previamente dentro de cada sucursal. Este análisis permite identificar no sólo qué sucursales presentan una mayor proporción de comentarios positivos o negativos, sino también qué temas aparecen con mayor frecuencia asociados a dichas percepciones en las reseñas de los usuarios.

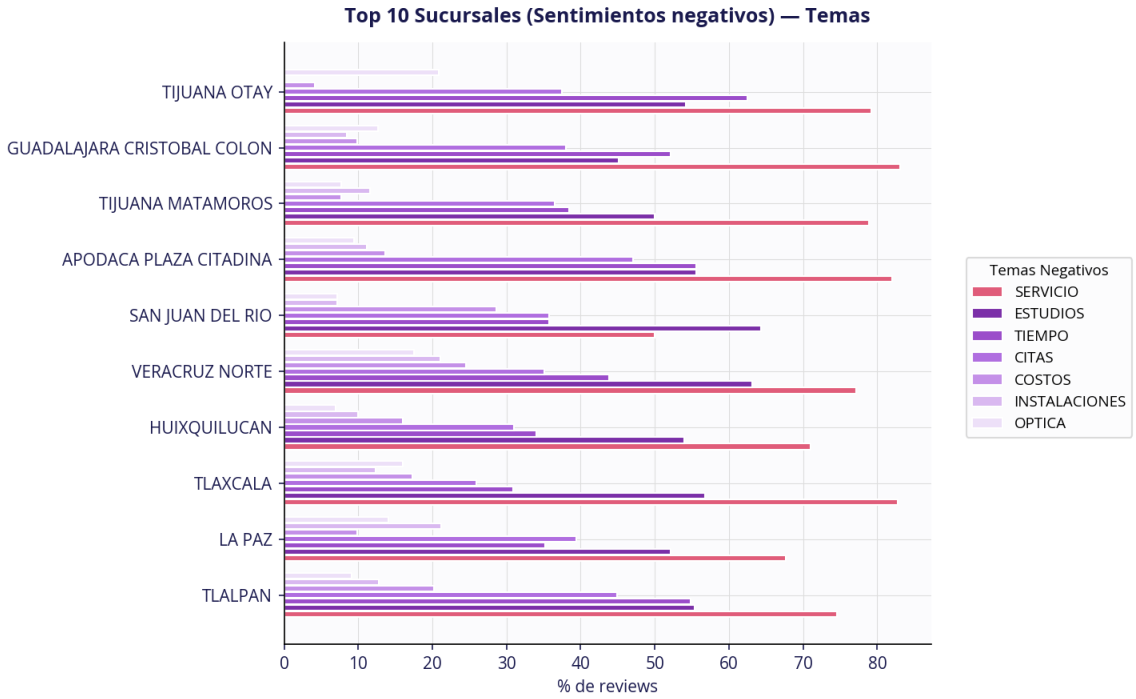

Ilustración 8 Temas recurrentes en las 10 sucursales con promedio score de sentimientos negativos más alto

La Ilustración 8 muestra las 10 sucursales con el promedio más alto en el score de sentimientos negativos. En estas se observa un patrón recurrente: el tema que aparece con mayor frecuencia en los comentarios es servicio, seguido por estudios y tiempo de atención. En contraste, los temas menos mencionados en este grupo de sucursales corresponden a óptica, instalaciones y costos. No obstante, se observan algunos casos particulares; por ejemplo, en Tijuana Otay el tema de óptica presenta una presencia mayor, mientras que en San Juan del Río el tema de estudios muestra una proporción más amplia dentro de los comentarios analizados.

Por otro lado, la Ilustración 9 muestra las 10 sucursales con el promedio más alto en el score de sentimientos positivos. En este caso también se observa un patrón relativamente consistente entre la mayoría de las sucursales: el tema servicio aparece con mayor frecuencia en los comentarios, seguido por costos, siendo más marcada la diferencia entre estos dos temas. En contraste, los temas citas y óptica se encuentran entre los menos mencionados dentro de este grupo de sucursales.

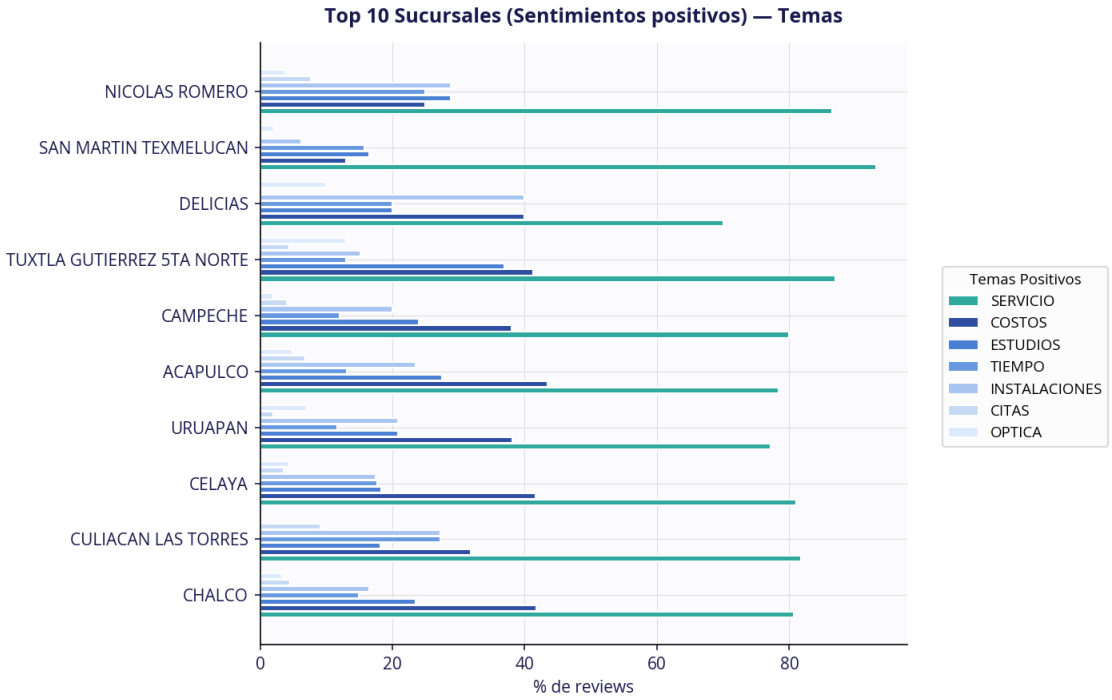

Ilustración 9 Temas recurrentes en las 10 sucursales con promedio score de sentimientos positivos más alto

En conjunto, estos resultados permiten observar que algunos temas, particularmente servicio, aparecen de forma recurrente tanto en comentarios positivos como negativos, lo que sugiere que se trata de un aspecto central en la experiencia descrita por los usuarios en las reseñas. Por otro lado, temas como óptica aparecen con menor frecuencia en general, lo que indica que son menos mencionados en comparación con otros aspectos del servicio.

El mapa interactivo en HTML (Ilustración 10.a) permite observar la distribución del sentimiento a lo largo de la red de sucursales en el país. Las sucursales con mayor volumen de reseñas no necesariamente presentan los índices de sentimiento más positivos; por otro lado, algunas sucursales con menor número de comentarios muestran índices de sentimiento elevados, lo que puede indicar una menor presencia de experiencias negativas documentadas por los usuarios. Ver anexo 4 para mapa interactivo.

El popup por sucursal (Ilustración 10.b) permite identificar de forma puntual los tres temas más recurrentes en cada ubicación, así como su sentimiento dominante y su proporción dentro de los comentarios analizados, así como el total de comentarios y si estos se encuentran por encima de la media de proporción de comentarios positivos.

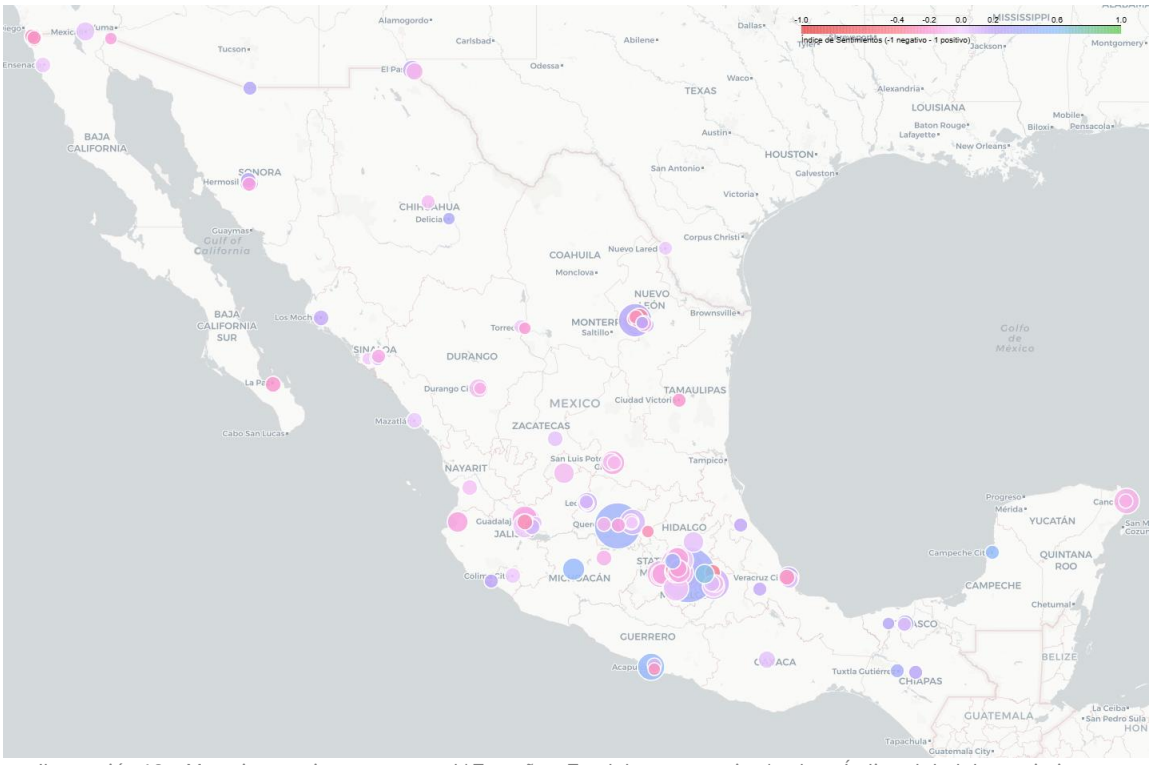

Ilustración 10.a Mapa interactivo por sucursal | Tamaño = Total de comentarios | color = Índice global de sentimientos

Ilustración 10.b Popup al interactuar con las sucursales del mapa

Este tipo de visualización permite identificar tendencias generales en los temas mencionados por los usuarios, así como detectar casos particulares en los que el patrón observado difiere del comportamiento más común entre las sucursales. De esta forma, los resultados pueden servir para comprender mejor la experiencia reportada por los usuarios y apoyar la identificación de áreas en las que se podrían implementar acciones de mejora a nivel general o bien intervenciones más específicas según el contexto de cada sucursal.

REFERENCIAS

- Cuantum Technologies. (2024). *Natural language processing with Python: From basics to advanced projects*. Cuantum Technologies. https://www.cuantum.tech/books/natural-language-processing-with-python-updated-edition

- Pérez, J. M., Rajngewerc, M., Giudici, J. C., Furman, D. A., Luque, F., Alonso Alemany, L., & Martínez, M. V. (2023). *pysentimiento: A Python toolkit for opinion mining and social NLP tasks*. arXiv. https://arxiv.org/abs/2106.09462

- Honnibal, M., Montani, I., Van Landeghem, S., & Boyd, A. (2020). *spaCy: Industrial-strength natural language processing in Python*. Explosion AI. https://spacy.io

- Explosion AI. (2024). *es_core_news_lg: Spanish language model for spaCy*. https://spacy.io/models/es

- Khananaev, G. (2026). *Google reviews scraper pro* [Código fuente]. GitHub. https://github.com/georgekhananaev/google-reviews-scraper-pro

- Python Visualization Library. (2024). *Folium: Python data, leaflet.js maps* (Version 0.16.0) [Software]. GitHub. https://github.com/python-visualization/folium

ANEXO

ANEXO 1: TOP 30 PALABRAS POSITIVAS Y NEGATIVAS

Palabra	Frecuencia
SERVICIO	4,416
CITA	2,802
ATENCIÓN	2,447
PÉSIMO	2,251
MAL	2,096
PERSONAL	1,671
ESTUDIOS	1,571
ULTRASONIDO	1,513
LENTES	1,500
TIEMPO	1,347
HORA	1,317
MALA	1,291
BIEN	1,182
ESTUDIO	1,166
RESULTADOS	1,070
HORAS	962
DÍA	960
HACEN	897
PERSONA	869
PÉSIMA	820
SALUD	820

Palabra	Frecuencia
SERVICIO	4,291
ATENCIÓN	4,092
EXCELENTE	3,915
PRECIOS	2,701
BUENA	2,185
BUEN	2,132
ACCESIBLES	1,479
PERSONAL	1,455
RÁPIDO	1,245
BIEN	1,229
ESTUDIOS	1,051
AMABLE	976
TRATO	972
AMABLES	931
LIMPIO	801
INSTALACIONES	748
RESULTADOS	715
BUENOS	682
CALIDAD	666
PRECIO	646
CITA	583

ESPERANDO	805
ESPERAR	791
DICEN	790
DESPUÉS	788
LABORATORIO	767
DIJO	756
TRATO	726
DIJERON	699
DAN	668

Tabla 2. a **TOP 30 palabras más frecuentes en reviews negativos**

LABORATORIO	574
RÁPIDA	525
ATIENDEN	500
SUPER	495
EXELENTE	487
LENTES	486
RECOMIENDO	472
SALUD	439
GRACIAS	417

Tabla 2.b **TOP 30 palabras más frecuentes en reviews positivos**

ANEXO 2. LISTA DE PALABRAS RAÍZ USADAS PARA CLASIFICAR LOS 7 TEMAS

```
       lemmas_tiempo = {'tarde', 'esperar', 'demorar', 'fila', 'hora', 'minuto', 'día',
                        'retraso', 'tardanza', 'rápido', 'puntualidad', 'eficiente',
                        'turno'}
     lemmas_servicio = {'atención', 'servicio', 'trato', 'personal', 'gente',
                        'atender', 'amable', 'grosero', 'accesibles', 'déspota',
                        'maleducado', 'amabilidad', 'profesional', 'recepción', 'turno',
                        'resultados'}
     lemmas_estudios = {'resultado', 'estudio', 'análisis', 'examen', 'entrega',
                        'muestra', 'laboratorio', 'ultrasonido', 'mastografía',
                        'resonancia', 'tomografía', 'densitometría', 'rayos x', 'sangre',
                        'radiología', 'incorrecto', 'dolor', 'calidad', 'toma', 'error',
                        'preciso'}
        lemmas_citas = {'cita', 'agendar', 'turno', 'programar', 'whatsapp', 'teléfono',
                        'reserva', 'llamar', 'internet', 'contestar', 'cancelar',
                        'sistema'}
       lemmas_costos = {'precio', 'costo', 'caro', 'barato', 'cobro', 'pago', 'factura',
                        'cobrar', 'barato', 'incorrecto', 'elevado', 'justo', 'tarjeta',
                        'accesible', 'económico'}
lemmas_instalaciones = {'sucio', 'limpio', 'baño', 'instalaciones', 'higiene',
                        'estacionamiento', 'lugar', 'bonito', 'organizado', 'moderno',
                        'cómodo', 'ordenado', 'olor', 'feo'}
       lemmas_optica = {'lente', 'lentes', 'graduación', 'armazón', 'optometrista',
                        'taller', 'vista', 'anteojos', 'defectuoso'}
```

ANEXO 3. GRÁFICA INTERACTIVA DE SUCURSALES

HTML

ANEXO 4. MAPA INTERACTIVO DE SUCURSALES

HTML